



实验二：K近邻与朴素贝叶斯

——分类和回归

PPT制作及出题人：
刘金杨（KNN）
商家煜（NB）



几点说明

1. 本次实验报告DDL为10月18日，但是10月12，13日要验收KNN
2. 如果报告有新版本，在文件名后面加后缀，例如“15351234_zhangsan_v1.xx”
3. 代码一定会进行查重，重复率达到不可接受的阈值按抄袭处理，不接受任何反驳。
4. python库只能用numpy（矩阵的运算也可以用）



实验报告内容

1. 算法原理：用自己的话解释一下自己对模型的理解
2. 伪代码：伪代码或者流程图（注意清晰简洁）
3. 关键代码截图：代码+注释
4. 创新点&优化：分点列出自己的创新点
5. 实验结果展示：用小数据测试自己的模型是否正确
6. 评测指标展示：基础模型的指标+与第4点中分点对应的优化后的指标（如果有）




- KNN和NB都是有监督的机器学习模型
- 有监督训练的步骤：
 - 给出带标签的训练数据
 - 用训练数据训练模型至一定程度
 - 用训练好的模型预测不带标签的数据的标签



- 分类问题：预测离散值的问题
——（如预测明天**是否**会下雨）
- 回归问题：预测连续值的问题
——（如预测明天气温是**多少度**）

k-NN处理分类问题



半径大小 表示 K值大小



k-NN处理分类问题

- 输入：原始文本
- 输出：类标签（happy, sadness...）
- 分类原则：多数投票原则

Document number	The sentence words	emotion
train 1	I buy an apple phone	happy
train 2	I eat the big apple	happy
train 3	The apple products are too expensive	sadnesss
test 1	My friend has an apple	?



步骤1：数据集的特征表示

数据集

Document number	The sentence words	emotion
train 1	I buy an apple phone	happy
train 2	I eat the big apple	happy
train 3	The apple products are too expensive	sadnesss
test 1	My friend has an apple	?

处理成One-hot矩阵

Document number	I	buy	an	apple	...	friend	has	emotion
train 1	1	1	1	1	...	0	0	happy
train 2	1	0	0	1	...	0	0	happy
train 3	0	0	0	1	...	0	0	sadness
test 1	0	0	1	1	...	1	1	?



步骤2：相似度计算

计算test1与每个train的欧氏距离
(也可以使用其他距离度量方式)

$$d(train1, test1) = \sqrt{(1-0)^2 + (1-0)^2 + \dots + (0-1)^2} = \sqrt{6};$$

$$d(train2, test1) = \sqrt{(1-0)^2 + (1-0)^2 + \dots + (0-1)^2} = \sqrt{8};$$

$$d(train3, test1) = \sqrt{(0-0)^2 + (0-0)^2 + \dots + (0-1)^2} = \sqrt{9};$$

若k=1, test1的标签即为train1的标签happy;

若k=3, test1的标签为train1,train2,train3的标签
中数量较多的, 即为happy。



k-NN处理回归问题

- 输入：原始文本
- 输出：属于某一类的**概率**（连续值）

Document number	The sentence words	the probability of happy
train 1	I buy an apple phone	0.8
train 2	I eat the big apple	0.6
train 3	The apple products are too expensive	0.1
test 1	My friend has an apple	?



步骤1：数据集的特征表示

数据集

Document number	The sentence words	the probability of happy
train 1	I buy an apple phone	0.8
train 2	I eat the big apple	0.6
train 3	The apple products are too expensive	0.1
test 1	My friend has an apple	?

处理成One-hot矩阵

Document number	I	buy	an	apple	...	friend	has	probability
train 1	1	1	1	1	...	0	0	0.8
train 2	1	0	0	1	...	0	0	0.6
train 3	0	0	0	1	...	0	0	0.1
test 1	0	0	1	1	...	1	1	?



步骤2：根据相似度加权

计算test1与每个train的距离，选取TopK个训练数据
把该距离的倒数作为权重，计算test1属于该标签的概率：

$$P(\text{test1 is happy}) = \frac{\text{train1 probability}}{d(\text{train1}, \text{test1})} + \frac{\text{train2 probability}}{d(\text{train2}, \text{test1})} + \frac{\text{train3 probability}}{d(\text{train3}, \text{test1})}$$

思考：为什么是倒数呢？

注意：同一测试样本的各个情感概率总和应该为1 如何处理？



不同距离度量方式

- 距离公式：

L_p 距离(所有距离的总公式)：

- $$L_p(x_i, x_j) = \left\{ \sum_{l=1}^n |x_i^{(l)} - x_j^{(l)}|^p \right\}^{\frac{1}{p}}$$

- $p = 1$ ：曼哈顿距离；
- $p = 2$ ：欧式距离，最常见。

（思考：在矩阵稀疏程度不同的时候，这两者表现有什么区别，为什么？）



不同距离度量方式

余弦相似度：

$\cos\left(\vec{A}, \vec{B}\right) = \frac{\vec{A} \cdot \vec{B}}{|\vec{A}| |\vec{B}|}$ ，其中 \vec{A} 和 \vec{B} 表示两个文本特征向量；

- 余弦值作为衡量两个个体间差异的大小的度量
- 为正且值越大，表示两个文本差距越小
- 为负代表差距越大，请大家自行脑补两个向量余弦值。



更多实验方法提高准确率

- 采用不同的距离度量方式
- 通过验证集对参数（K值）进行调优
- 对权值进行归一化

Name	Formula	Explain
Standard score	$X' = \frac{X - \mu}{\sigma}$	<u>μ is the mean and σ is the standard deviation</u>
Feature scaling	$X' = \frac{X - X_{min}}{X_{max} - X_{min}}$	X_{min} is the min value and X_{max} is the max value

PS：关于k的经验公式：一般取 $k = \sqrt{N}$ ，N为训练集实例个数，大家可以尝试一下



训练集 验证集 测试集的区别

数据类型	有无标签	作用
训练集(training set)	有	用来 训练模型 或确定模型参数的，如k-NN中权值的确定等。 相当于平时练习。
验证集(validation set)	有	用来 确定 网络结构或者控制模型复杂程度的 参数 ， 修正模型 。 相当于模拟考试。
测试集(test set)	无	用于检验最终选择最优的模型的性能如何。 相当于期末考试。



训练集 验证集 测试集的使用

- 一个典型的划分是训练集占总样本的50%，而其它各占25%，三部分都是从样本中随机抽取。
- 本次实验分类任务和回归任务都出了训练集，验证集和测试集。
- validation.xlsx文件用于在验证集上进行结果的评估，使用相关系数，大家把验证集上的预测结果，粘贴在Predict工作表中，右边会产生结果。Standard工作表不要修改内容。



KNN实验任务

- 分类（使用准确率进行衡量结果）

1. 使用KNN处理分类问题。在验证集上，通过调节K值、选择不同距离等方式得到一个准确率最优的模型参数，并将该过程记录在实验报告中。
2. 在测试集上应用步骤1中得到的模型参数（K，距离类型等），将输出结果保存为“学号_姓名拼音_KNN_classification.csv”，
文件内部格式参考“15351234_Sample_KNN_classification.csv”

- 回归（使用相关系数进行衡量结果）

1. 使用KNN处理回归问题，在验证集上，通过调节K值、选择不同距离等方式得到一个相关系数最优的模型参数，并将该过程记录在实验报告中。这一步可以通过使用“validation相关度评估.xlsx”文件辅助验证（也可以自己写代码）。
2. 在测试集上应用步骤1中得到的模型参数（K，距离类型等），将输出结果保存为“学号_姓名拼音_KNN_regression.csv”，
文件内部格式参考“15351234_Sample_KNN_regression.csv”



Naïve Bayes

BAYES RULE



REV THOMAS BAYES



实验课内容



Example: $P_{(c)} = 0.01$

Sensitivity -> 真阳性

Test: 90% it is positive if you have cancer

$$P_{(Pos|c)} = 0.9$$


Specificity -> 假阴性

90% it is negative if you don't have cancer

$$P_{(Neg|\neg c)} = 0.9$$

Question: If Test = Positive

Probability of having cancer





Prior:

$$P_{(c)} = 0.01$$

$$P_{(\text{Pos}|c)} = 0.9$$

$$P_{(\text{Neg}|\neg c)} = 0.9$$



$$P_{(\neg c)} = 0.99$$

$$P_{(\text{Pos}|\neg c)} = 0.1$$

Posterior:

$$p(y|x) = \frac{p(x, y)}{p(x)} = \frac{p(x|y)p(y)}{p(x)}$$



Joint: $P_{(c, pos)} = P_{(c)} * P_{(Pos|c)} = 0.009$

$$P_{(\neg c, pos)} = P_{(\neg c)} * P_{(Pos|\neg c)} = 0.099$$

normalizer: $P_{(pos)} = P_{(c, pos)} + P_{(\neg c, pos)} = 0.108$

Posterior : $P_{(c|pos)} = 0.0833$

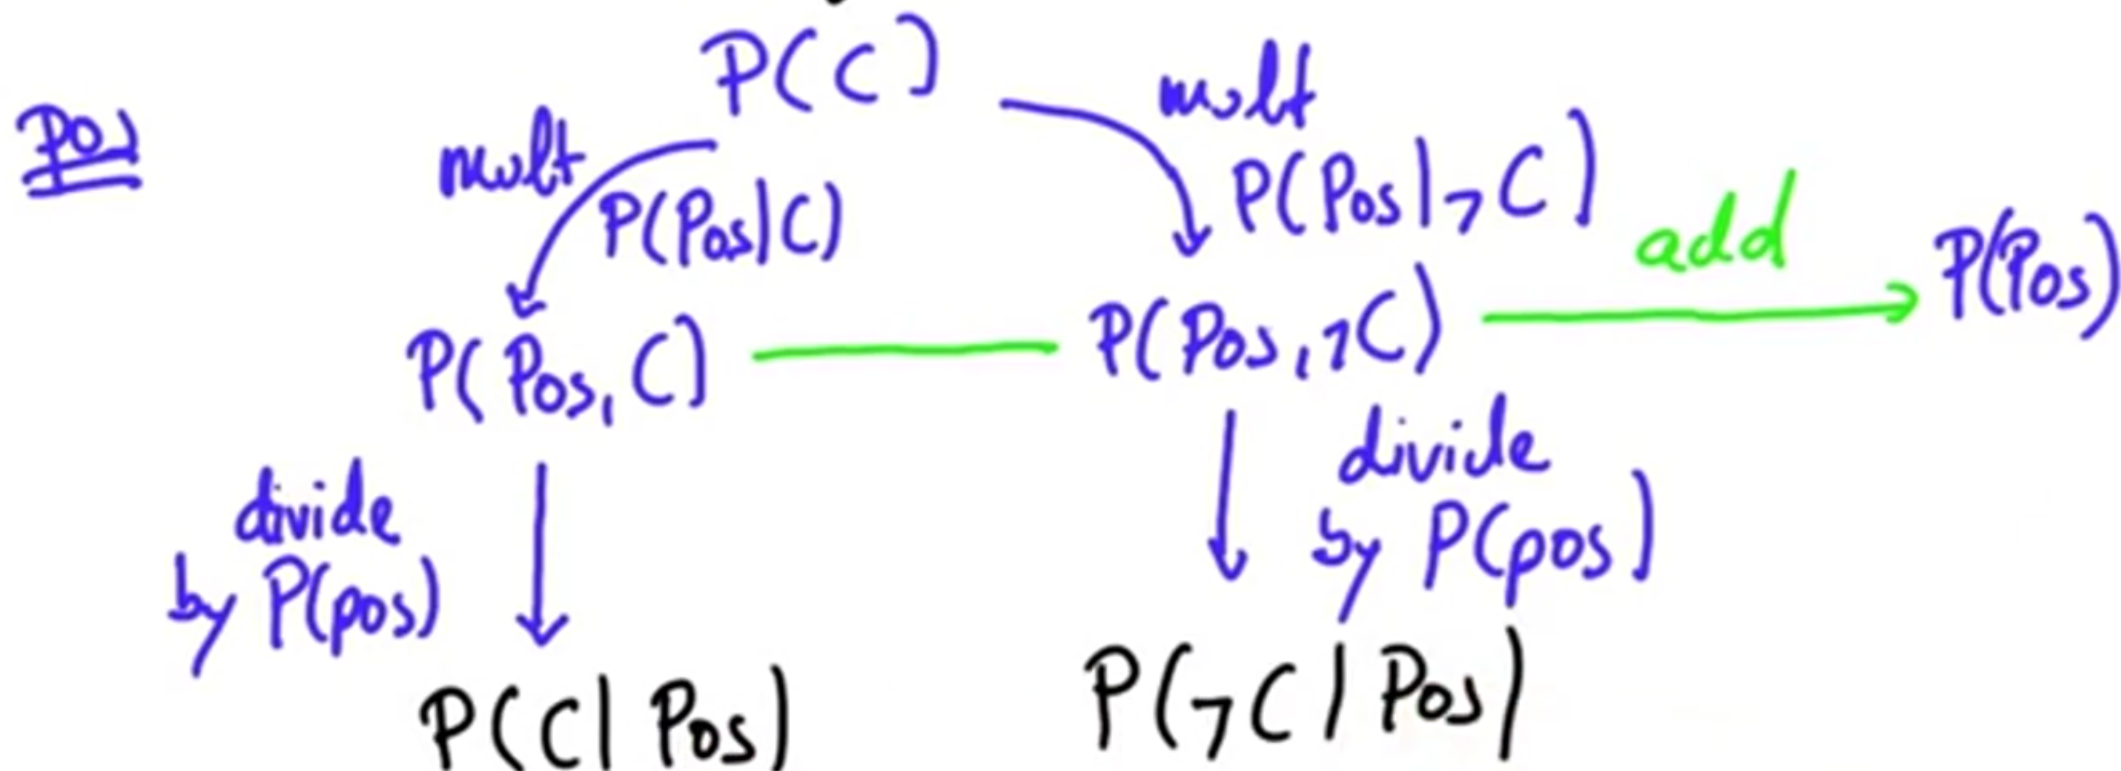
$$P_{(\neg c|pos)} = 0.9167$$



$P(C)$ prior

$P(Pos|C)$ sensitivity

$P(Neg|\neg C)$ specificity





Bayes rule

$$p(y|x) = \frac{p(x, y)}{p(x)} = \frac{p(x|y)p(y)}{p(x)}$$

known

where $p(x)$ is a **constant** for all classes. Take animal classification as example: $p(x) = p(x|y=0)p(y=0) + p(x|y=1)p(y=1)$

Thus NB is to find

$$\begin{aligned} y &= \arg \max_y p(y|x) = \arg \max_y \frac{p(x, y)}{p(x)} \\ &= \arg \max_y p(x|y)p(y) \end{aligned}$$



Classification for Naïve Bayes



Classification for Naïve Bayes

Bernoulli Model (伯努利模型) : a document is represented by a feature vector with **binary** elements taking value 1 if the corresponding word is present in the document and 0 if the word is not present.

$$p(x_k|e_i) = \frac{n_{e_i}(x_k)}{N_{e_i}} \quad p(e_i) = \frac{N_{e_i}}{N}$$

where $n_{e_i}(x_k)$ is the number of documents of emotion e_i in which x_k is observed, and N_{e_i} and N is the number of documents with emotion e_i and total documents, respectively.



Classification for Naïve Bayes

Multinomial Model (多项式模型) : a document is represented by a feature vector with integer elements whose value is the **frequency** of that word in the document.


$$p(x_k|e_i) = \frac{nw_{e_i}(x_k)}{nw_{e_i}} \quad p(e_i) = \frac{N_{e_i}}{N}$$

where $nw_{e_i}(x_k)$ is the number of times word x_k occurs in documents with emotion e_i , and nw_{e_i} is the total number of words occurs in documents with emotion e_i .



Example

ID	text	class label
1	good,thanks	joy
2	No impressive, thanks	sad
3	Impressive good	joy
4	No, thanks	?



ID	goods	thanks	no	impressive	class label
1	1	1	0	0	joy
2	0	1	1	1	sad
3	1	0	0	1	joy
4	0	1	1	0	?

Bernoulli Model (伯努利模型) :

$$P_{(\text{thanks}|\text{joy})} = 1/2$$

Multinomial Model (多项式模型) :

$$P_{(\text{thanks}|\text{joy})} = 1/4$$

思考题：这两个模型分别有什么优缺点



Classification(多项式模型)

ID	text	class label
1	good,thanks	joy
2	No impressive, thanks	sad
3	Impressive good	joy
4	No, thanks	?



update--baserow onehot
create 6 motion voc base

ID	goods	thanks	no	impressive	class label
1	1	1	0	0	joy
2	0	1	1	1	sad
3	1	0	0	1	joy
4	0	1	1	0	?

joy
sad
disgust
surprise
anger
fear

Target function:

$$p(\text{joy}|d_4) = p(\text{joy}) \cdot p(d_4|\text{joy})$$

$$p(\text{sad}|d_4) = p(\text{sad}) \cdot p(d_4|\text{sad})$$

Example:

$$\begin{aligned} p(\text{joy}|d_4) &= p(d_4|\text{joy}) \cdot p(\text{joy}) \\ &= p(\text{" thanks" , " no" }|\text{joy}) \cdot p(\text{joy}) \\ &= p(\text{" thansk" }|\text{joy}) \cdot p(\text{" no" }|\text{joy}) \cdot p(\text{joy}) \\ &= \frac{1}{4} \times 0 \times \frac{2}{3} = 0 \end{aligned}$$



Regression for Naïve Bayes



Example

Documnt	sentence	joy	sad
train1 (d1)	Step by step, we will succeed.	0.9	0.1
train2 (d2)	We step on shit.	0.3	0.7
test1 (d3)	We succeed.	?	?

Figure: Example of documents

X	x_1	x_2	x_3	x_4	x_5	x_6	x_7	emotion	
Document	step	by	we	succeed	on	shit	will	joy	sad
train1 (d1)	0.33	0.17	0.17	0.17	0	0	0.17	0.9	0.1
train2 (d2)	0.25	0	0.25	0	0.25	0.25	0	0.3	0.7
test1 (d3)	0	0	0.5	0.5	0	0	0	?	?

Figure: TF features of documents



Example

To predict emotion e_i of test document $X_3 = (x_3, x_4)$, we need to estimate:

$$\arg \max_{e_i} p(e_i | X) = \arg \max_{e_i} \sum_{j=1}^M \prod_{k=1}^{K'} p(x_k | e_i, d_j) p(d_j, e_i)$$

$$\begin{aligned} p(\text{joy} | X_3) &\propto p(x_3 | \text{joy}, d_1) p(x_4 | \text{joy}, d_1) p(d_1, \text{joy}) \\ &\quad + p(x_3 | \text{joy}, d_2) p(x_4 | \text{joy}, d_2) p(d_2, \text{joy}) \\ &= \underbrace{0.17}_{\text{map}\langle \text{string}, \text{int} \rangle} \times 0.17 \times 0.9 + 0.25 \times 0 \times 0.3 = 0.02601 \end{aligned}$$

$$\begin{aligned} p(\text{sad} | X_3) &\propto p(x_3 | \text{sad}, d_1) p(x_4 | \text{sad}, d_1) p(d_1, \text{sad}) \\ &\quad + p(x_3 | \text{sad}, d_2) p(x_4 | \text{sad}, d_2) p(d_2, \text{sad}) \\ &= 0.17 \times 0.17 \times 0.1 + 0.25 \times 0 \times 0.7 = 0.00289 \end{aligned}$$



Example

Normalize the posterior distribution:

$$p'(joy|X_3) = \frac{0.02601}{0.02601 + 0.00289} = 0.9$$

$$p'(sad|X_3) = \frac{0.00289}{0.02601 + 0.00289} = 0.1$$



Laplace Smoothing

Notice that if the word x_k in test document does not occur in the training set, $p(x_k|d_j, e_i)$ will be zero and thus cause the resulting value becoming 0.

Solution: **Laplace Smoothing!** (拉普拉斯平滑)

- regression model:

$$p(x_k|d_j, e_i) = \frac{x_k + 1}{\sum_{k=1}^K x_k + K}$$

- classification model:

$$\text{Bernoulli} : p(x_k|e_i) = \frac{n_{e_i}(x_k) + 1}{N_{e_i} + 2}$$

$$\text{Multinomial} : p(x_k|e_i) = \frac{nw_{e_i}(x_k) + 1}{nw_{e_i} + \underline{V_{e_i}}}$$

where nw_{e_i} is the total number of words in documents with emotion e_i , and V_{e_i} is the number of non-repetitive words with label e_i .



Task

- (1) 分类 (使用**准确率**衡量结果)
分类只要求实现**多项式模型**
- (2) 回归 (使用**相关系数**衡量结果)
 - 归一化最后的情感概率, 使得六中情感概率相加为 1
 - 本次实验同样提供了 validation 数据集
- (3) 推荐实现拉普拉斯平滑

思考题: 如果测试集中出现了一个之前全词典中没有出现过的词该如何解决



数据说明

总共 **两个压缩包：**

classification_dataset和**regression_dataset**

里面分别有三个文件，分别用作**train**、**validation**、**test**

从外，**regression**另外提供了一个相似度评估文件。



提交文件

- 总共 **两个结果文件**：

“学号_姓名拼音_NB_classification.csv”，

“学号_姓名拼音_NB_regression.csv”，

打包，**正确命名**后上交ftp。

文件内部格式参考“15351234_Sample_NB_classification.csv”

文件内部格式参考“15351234_Sample_NB_regression.csv”

- **代码文件** **尽量** 是写在一个代码文件里，，如果有多个代码文件，打包，正确命名后上交ftp。
- 报告中要有 **所有任务的结果展示**，报告提交PDF版本，请勿提交word文件，避免排版混乱。



两次实验共提交文件

-----FTP

-----班级

-----报告

-----一份报告

-----结果

-----包含两个实验4个结果的压缩包（采用zip格式，“发送到”压缩）

-----代码

-----包含两个实验2份代码的压缩包（采用zip格式，“发送到”压缩）

如果对此次实验题目有疑问，请联系刘金杨和商家煜。



注意事项

1、作业提交地址

FTP地址：<ftp://39.108.233.34>

登录用户名与密码均为 student

提交文件夹的名字是 labx_yyyyddmmend, x为第几次实验, yyyyddmmend是指截止日期, 比如 20171018end

2、命名方式

查询“实验课须知”, 实验报告, 所有代码文件以及结果文件都需要上交。

3、编程语言可用 C++, python, matlab, java等, **不能使用现成库 (如 sklearn 等)**, 否则扣分

4、提交截止时间

2017年10月18日23: 59: 59前